Journal de bord

Mondes vivants · Sujet 04 ÉPHÉMÈRE · Simulation multi-agents du lancement d'une crème solaire fictive

> **À quoi sert ce document.** Après chaque étape du développement, on y explique ce qui a été fait, pourquoi, et ce qu'il faut retenir pour pouvoir le présenter au jury. Il se lit dans l'ordre : chaque étape s'appuie sur les précédentes. Les règles permanentes du projet sont dans `CLAUDE.md`, les décisions de conception dans `docs/contexte-projet.md`.

Le plan de travail

Le projet repart de zéro le 16 octobre 2026. Chaque étape est validée par le binôme avant de passer à la suivante, puis fait l'objet d'un commit. Les codes entre parenthèses renvoient aux exigences de l'énoncé.

#	Étape	Contenu	État
Phase 0 — Faire place nette			
0	Nettoyage du dépôt	Retrait du prototype non conforme, mise à jour de CLAUDE.md, README et journal	terminée
Phase 1 — Fondations			
1	Squelette du dépôt	Arborescence, `.gitignore`, `.env.example`, Python 3.12, ruff, fichier de configuration	terminée
2	Infrastructure Docker	Kafka (KRaft) et Redis en versions figées, création des 7 topics `sim.*`	terminée
3	Mesure de la machine	Réglages Ollama, benchmark par modèle en séquentiel puis en parallèle (E4)	terminée
Phase 2 — Le cœur, sans contenu du monde			
4	Contrat d'événements	Enveloppe Pydantic versionnée, deux horloges, `caused_by`, file `sim.dlq` (F4, C3, F6)	à venir
5	Horloge et orchestrateur	Mode synchrone, délai de livraison, `run_id` et graine (C2, C3)	à venir
6	Couche LLM	Sortie JSON imposée, routeur par palier, relance puis repli, incidents, coûts (A4, A5, E4)	à venir
7	Tranche verticale	3 agents LLM et 1 agent à règles sur 5 pas, lus par un client console	à venir
8	Historique et rejeu	Écriture Parquet, relecture d'un run sans appel LLM (E3, F5)	à venir
Phase 3 — Visualisation			
9	Pont FastAPI	WebSocket en direct ou en rejeu, inspection (D2), injection (D3)	à venir
10	Scène Godot 3D	Bâtiments distincts par zone, plage avec sable et mer, personnages animés, panneau d'indicateurs (D1)	à venir
Phase 4 — Le monde et ses agents			
11	Le monde	Nom de marque et test de contamination, population complète, seuils d'adoption	à venir

12	Corpus et RAG	Documents fictifs, ChromaDB, filtres par date et par rôle, mémoires, évaluation (F1, F2, A1, C6)	à venir
13	Agents à règles et baseline	Météo, vendeurs, concurrent, fidèles ; baseline C0 avec la même saisonnalité (A6, E1)	à venir
14	Indicateurs	Sens partagé, adoption, traçabilité, run témoin, taux de sortie de rôle (B1-B3, F6)	à venir
15	Mode asynchrone	Deuxième mode d'exécution, violations temporelles comptées (C4, C6)	à venir
Phase 5 — Preuves et soutenance			
16	Expériences	Configurations C0 à C3, au moins 5 runs chacune, Bass, synchrone/asynchrone, coûts (E1, E2, E4, E5, C5)	à venir
17	Charge et pannes	Agent muet, pic d'événements, latence jusqu'aux indicateurs (O4, C7)	à venir
18	Soutenance	Configuration de démo réduite, deux tailles de population (C8), README, run enregistré, rapport	à venir

Pourquoi cet ordre. On construit d'abord la tuyauterie (événements, horloge, appels LLM) avec très peu d'agents, pour vérifier que tout circule. Le rejeu arrive tôt (étape 8) parce qu'il permet ensuite de développer la scène 3D sur des runs enregistrés, sans occuper la carte graphique avec les modèles. Le contenu du monde (marque, corpus, population complète) vient une fois la chaîne fiable.

Étape 0 — Nettoyage du dépôt

16 octobre 2026 · Exigences concernées : aucune directement ; prépare toutes les suivantes.

Objectif

Repartir d'une base propre : ne garder dans le dépôt que ce qui est conforme aux règles du projet (`CLAUDE.md`), aux décisions de conception (`docs/contexte-projet.md`) et à l'énoncé.

Pourquoi on a repris de zéro

Un premier prototype avait été écrit avant que la conception soit arrêtée. En le comparant aux règles du projet, plusieurs écarts sont apparus, dont certains touchent des exigences notées :

Écart dans le prototype	Règle ou exigence concernée
Nom de marque, ingrédient et indice de protection écrits en dur dans le code et les prompts	Le nom doit rester un paramètre de configuration, choisi après un test de contamination
Topics `simulation.*` au lieu des 7 topics `sim.*` prévus	C1, architecture
Événements sans `run_id`, sans `caused_by`, et date de traitement en temps réel au lieu du temps simulé	C3 (deux horloges), F6 (traçabilité), E3 (rejeu)
Pas de Redis ; images Docker en version `latest`	F3 ; livrable reproductible sur une autre machine
Pas de `.gitignore`, fichiers compilés Python versionnés, arborescence différente	Conventions du dépôt
Visualisation 2D à base d'icônes	Remplacée par une scène 3D (décision du binôme)

Corriger ces écarts un par un aurait coûté plus cher que de reconstruire proprement, étape par étape.

Ce qui a été fait

- **Retrait du prototype du dépôt** : `src/`, `godot_client/`, `docker-compose.yml`, `requirements.txt`. Ces fichiers avaient été commités, ils restent donc consultables dans l'historique git (commit `607297b`).
- **Archivage hors du dépôt** des fichiers jamais commités, qu'une suppression aurait perdus définitivement : `src/agents/`, `src/rag/`, `src/simulation_engine.py`, `data/knowledge/`, les caches Godot et l'environnement virtuel. Ils sont dans `C:\Users\Siradiou\archive_prototype_S9_2026-10-16\`.
- **Mise à jour de `CLAUDE.md`** : chemin correct de l'énoncé, Python 3.12, Godot en 3D low-poly, et une section « Méthode de travail » qui fixe la règle d'avancement étape par étape.
- **Journal des décisions** complété dans `docs/contexte-projet.md`.
- **Création du `README.md`** : description du projet pour GitHub et tableau d'avancement, mis à jour à chaque commit.
- **Installation de Python 3.12.10** avec le gestionnaire d'installation officiel (`py install 3.12`), pour l'utilisateur seulement, sans droits administrateur. Python 3.14 reste installé et reste la version par défaut ; on appelle 3.12 explicitement avec `py -V:3.12`.
- **Création de ce journal de bord** : source HTML dans `docs/journal/journal-de-bord.html`, PDF généré à la racine par `docs/journal/build.ps1` (impression via Microsoft Edge, déjà présent sous Windows, donc aucune dépendance à installer).

Décisions prises à cette étape

Décision	Raison
Python **3.12**	Version stable bien prise en charge par les bibliothèques prévues (ChromaDB notamment), qui suivent souvent les nouvelles versions de Python avec retard. Python 3.12.10 a été installé à côté de 3.14 (voir ci-dessous).
Scène Godot en **3D low-poly**, rendu léger	Plus lisible et plus parlante pour le jury, tout en laissant de la mémoire graphique aux modèles LLM (budget d'environ 1 à 1,5 Go pour Windows et Godot).
Modèles 3D gratuits choisis sur maquettes	Plusieurs essais seront présentés au binôme, qui choisira (étape 10).
Avancement étape par étape, commit après validation	Chaque étape est comprise et expliquable par les deux membres avant d'aller plus loin.

État du dépôt après l'étape

```
CLAUDE.md                règles permanentes du projet
README.md                présentation et état d'avancement
journal-de-bord.pdf      ce document
docs/
  contexte-projet.md     décisions de conception
  Architecture_…pdf      schémas d'architecture
  Mondes-Vivants_…html   énoncé
  journal/
    journal-de-bord.html source de ce document
    build.ps1            génération du PDF
```

À retenir pour l'oral

- Le projet a été reconstruit sur une conception écrite et validée avant de coder, pour que chaque composant réponde à une exigence identifiée de l'énoncé.
- Interpréteur et environnement virtuel sont deux choses distinctes : Python 3.12 est installé une fois sur la machine, puis l'environnement virtuel `.venv` du projet (étape 1) est créé à partir de lui et contient toutes les bibliothèques. Ainsi les dépendances du projet n'interfèrent pas avec le reste de la machine, et la procédure se reproduit sur la machine de la collaboratrice.
- Rien n'a été perdu : l'ancien code est dans l'historique git ou archivé.

Prochaine étape

Étape 1 — Squelette du dépôt : environnement virtuel `.venv` en Python 3.12, arborescence, `.gitignore`, `.env.example`, outillage ruff, et fichier de configuration qui portera `BRAND_NAME`, le nombre d'agents, le mode d'exécution et la graine.

Étape 1 — Squelette du dépôt

16 octobre 2026 · Exigences concernées : C2 (nombre d'agents fixé au lancement), livrable « reproductible sur une autre machine, versions figées ».

Objectif

Poser le cadre dans lequel tout le code viendra se ranger : un environnement Python isolé et reproductible, une arborescence qui suit l'architecture, des outils de qualité, et un fichier de configuration qui centralise tous les paramètres d'un run.

Ce qui a été fait

- **Environnement virtuel** `.venv` créé à partir de Python 3.12.10. Toutes les bibliothèques du projet y sont installées, rien sur le reste de la machine.
- **Arborescence** : un dossier par composant de l'architecture (`sim`, `agents`, `llm`, `bus`, `rag`, `indicators`, `bridge`, `replay`), plus `corpus`, `godot`, `configs` et `tests`. Chaque paquet Python porte une phrase qui dit à quoi il sert.
- `pyproject.toml` : fiche d'identité du projet. Il déclare les dépendances directes avec leur version exacte, configure ruff (style et erreurs courantes) et pytest.
- `requirements.lock` : liste complète et figée de toutes les bibliothèques installées, y compris les dépendances indirectes.
- `.gitignore` : exclut l'environnement virtuel, les caches, le fichier de secrets `.env`, les sorties de runs et le cache de Godot.
- `.env.example` : modèle du fichier de secrets, sans valeur (adresses d'Ollama, Kafka, Redis ; clés d'API facultatives).
- **Configuration** : `configs/default.yaml` et son chargeur `sim/config.py`, plus la liste des 11 rôles dans `agents/roles.py`.
- **11 tests automatisés** dans `tests/test_config.py`.

Décisions prises à cette étape

Décision	Raison
pip + fichier verrou	Outils standards de Python, rien à apprendre en plus. Le verrou fige aussi les dépendances indirectes : la collaboratrice obtient exactement les mêmes versions.
Configuration en YAML, validée par Pydantic	Lisible et commentable, prévu dans le document d'architecture. La validation transforme une faute de frappe en erreur claire au lancement plutôt qu'en comportement faux au milieu d'un run.
Une dépendance n'arrive qu'avec l'étape qui l'utilise	Chaque bibliothèque du projet est justifiée et expliquable. Ainsi `python-dotenv` (lecture de `.env`) attendra l'étape 2.
Nom de marque provisoire `MARQUE_PROVISOIRE`	Le vrai nom sera choisi à l'étape 11 après le test de contamination. Comme il n'existe que dans la configuration, le changer ne touchera aucun code.

Comment fonctionne la configuration

Un run est entièrement décrit par un fichier YAML en quatre sections :

Section	Contenu	Valeur par défaut
`run`	Graine du générateur aléatoire	42
`simulation`	Durée simulée en jours, mode d'exécution	90 jours, synchrone
`monde`	Nom de marque, ingrédient phare, indice de protection (fictifs)	valeurs provisoires
`population`	Nombre d'agents pour chacun des 11 rôles	120 agents, dont 84 LLM

Au chargement, `load_config` vérifie chaque valeur. Sont refusés : une durée nulle, une graine négative, un mode autre que `synchrone` ou `asynchrone`, un nom de marque vide, un rôle inconnu, un effectif négatif, une population vide, et toute clé mal orthographiée (par exemple `duree_jour` au lieu de `duree_jours`). L'erreur indique le fichier et le champ fautif.

> **Lien avec l'exigence C2.** Pour changer le nombre d'agents, on modifie la section `population` du fichier YAML, ou on crée un autre fichier dans `configs/`. Le code ne change pas. Un test le vérifie avec une population de 4 agents.

Les tests

Test	Ce qu'il garantit
`test_default_config_matches_design`	La configuration par défaut correspond à la conception : 120 agents, 90 jours, mode synchrone, les 11 rôles présents.
`test_agent_count_comes_from_config`	Le nombre d'agents vient bien du fichier (C2).
`test_invalid_values_are_rejected` (7 cas)	Chaque valeur invalide listée plus haut est refusée.
`test_empty_population_is_rejected`	Un run sans agent est refusé.
`test_missing_file_gives_clear_error`	Un fichier absent donne une erreur lisible.

Résultat : 11 tests réussis, aucune remarque de ruff. La procédure d'installation du README a été rejouée dans un environnement neuf pour vérifier qu'elle fonctionne telle qu'écrite.

État du dépôt après l'étape

```
pyproject.toml        identité du projet, dépendances directes, ruff, pytest
requirements.lock     toutes les versions figées
.gitignore  .env.example
configs/default.yaml  configuration principale (120 agents, 90 jours)
sim/config.py         chargement et validation de la configuration
agents/roles.py       les 11 rôles
tests/test_config.py  11 tests
sim/ agents/ llm/ bus/ rag/ indicators/ bridge/ replay/   paquets Python
corpus/ godot/        à remplir aux étapes 10 et 12
```

À retenir pour l'oral

- Un run est entièrement décrit par un fichier de configuration et une graine : c'est la base de la reproductibilité (E2, E3) et de l'exigence C2.

- La configuration est validée avant le lancement : une erreur de saisie ne peut pas fausser un run silencieusement.
- Les versions sont figées à deux niveaux (`pyproject.toml` pour les dépendances directes, `requirements.lock` pour toutes), ce qui répond à l'exigence de livrable reproductible sur une autre machine.

Prochaine étape

Étape 2 — Infrastructure Docker : Kafka en mode KRaft et Redis, versions figées, création des 7 topics `sim.*`, et vérification que Python peut y écrire et y lire.

Étape 2 — Infrastructure Docker : Kafka et Redis

16 octobre 2026 · Exigences concernées : C1 (événements transportés par Kafka), F3 (où vit chaque donnée), livrable reproductible.

Objectif

Mettre en place les deux services qui tournent à côté de la simulation : **Kafka**, le bus par lequel passent tous les événements, et **Redis**, qui garde l'état courant du monde. Vérifier que le code Python sait y écrire et y relire.

Rappel : à quoi servent ces deux services

Service	Rôle dans le projet	Pourquoi lui
Kafka	Journal ordonné de tous les événements : décisions des agents, messages, météo, indicateurs, incidents. Les agents ne s'appellent jamais directement, ils publient et lisent des événements.	Imposé par l'énoncé (C1). Garde l'ordre, permet de relire un flux, découple la simulation de Godot et des indicateurs.
Redis	État courant : stocks, météo, qui est dans quelle zone. Lu et écrit très souvent par les agents et par le pont vers Godot.	Base en mémoire, réponse en moins d'une milliseconde. Les données sont éphémères (F3).

Ce qui a été fait

- `docker-compose.yml` : décrit les deux conteneurs, avec des versions exactes (`apache/kafka:4.3.1`, `redis:8.8.3-alpine`) et un contrôle de santé pour chacun. `docker compose up -d --wait` les lance et attend qu'ils soient prêts.
- `bus/topics.py` : la liste des 7 topics sous forme d'énumération Python, et la commande `python -m bus.topics` qui crée ceux qui manquent. Elle peut être relancée sans risque : un topic déjà présent n'est pas recréé.
- `sim/settings.py` : lit les adresses des services dans `.env`. Sans fichier `.env`, les valeurs par défaut conviennent pour un poste local.
- **Trois bibliothèques ajoutées** : `aiokafka` (client Kafka compatible avec `asyncio`, que l'orchestrateur utilisera), `redis` (client Redis, avec une version `asyncio`) et `python-dotenv` (lecture de `.env`).
- **5 nouveaux tests**, dont 3 tests d'intégration qui parlent aux vrais services.

Les 7 topics

Topic	Ce qui y passe	Exigences
`sim.world.events`	Événements du monde : météo, stocks, promotions, événements injectés	C1, D3
`sim.agent.messages`	Échanges en langage naturel entre agents	A2
`sim.agent.decisions`	Action et sens déclarés par chaque agent	B1, D2
`sim.indicators`	Indicateurs calculés pendant le run	B2, F6
`sim.control`	Commandes et injections depuis l'interface	D3
`sim.incidents`	Sorties LLM invalides, replis, violations temporelles	A4, C6
`sim.dlq`	Événements qui ne respectent pas leur schéma (« dead letter queue »)	F4

Choix de configuration et leurs raisons

Choix	Raison
Kafka en mode **KRaft**, un seul nœud	Depuis Kafka 4, ZooKeeper n'existe plus : Kafka gère lui-même ses métadonnées. Un seul nœud suffit sur un portable.
Une partition par topic	Kafka ne garantit l'ordre qu'à l'intérieur d'une partition. Avec une seule partition, tous les événements d'un topic sont relus exactement dans l'ordre d'écriture, ce qui est indispensable pour rejouer un run à l'identique (E3). Le débit d'une partition dépasse de loin nos quelques dizaines de milliers d'événements par run.
Rétention de **7 jours**	Kafka sert de transport, pas d'archive. L'historique durable sera écrit en Parquet à l'étape 8 (F3).
Création automatique des topics **désactivée**	Par défaut, Kafka crée un topic dès qu'on écrit dedans. Une faute de frappe dans un nom créerait alors un topic fantôme où les événements se perdraient sans erreur. Désactivée, l'erreur est immédiate.
Mémoire de Kafka limitée à **1 Go**	Laisse la RAM aux autres composants. Mesuré au repos : 360 Mo pour Kafka, 5 Mo pour Redis.
Redis **sans persistance** sur disque	L'état courant est reconstruit à chaque run ; le sauvegarder ne servirait à rien et ralentirait les écritures.
Ollama **hors de Docker**	Sous Windows, donner le GPU à un conteneur ajoute de la complexité sans bénéfice (décision du document d'architecture).

Les tests

Test	Ce qu'il garantit
`test_all_topics_exist_with_expected_settings`	Les 7 topics existent, chacun avec une seule partition.
`test_kafka_roundtrip_preserves_order`	20 messages écrits dans un topic temporaire sont relus à l'identique et dans le même ordre ; le topic est supprimé ensuite.
`test_redis_roundtrip`	Une écriture dans Redis est relue correctement.
`test_defaults_match_env_example`	Sans `.env`, les adresses par défaut sont utilisées.
`test_env_file_and_environment`	`.env` est bien lu, et une variable d'environnement le remplace si elle est définie.

Résultat : **16 tests réussis**, aucune remarque de ruff. On a aussi vérifié que, si les services sont arrêtés, les tests d'intégration sont ignorés avec le message « lancer `docker compose up -d` » au lieu d'échouer.

État du dépôt après l'étape

```
docker-compose.yml       Kafka 4.3.1 (KRaft) + Redis 8.8.3, versions figées
bus/topics.py            les 7 topics et leur création
sim/settings.py          adresses des services, lues dans .env
tests/test_infra.py      3 tests d'intégration (Kafka, Redis)
tests/test_settings.py   2 tests de lecture de .env
```

À retenir pour l'oral

- Kafka est le seul moyen de communication entre composants : c'est ce qui rend un run enregistrable, rejouable et observable sans modifier la simulation.
- Une partition par topic donne un ordre total des événements : c'est un choix délibéré au service du rejeu, pas une limite.
- Chaque stockage a un rôle et une durée de vie : Kafka transporte (7 jours), Redis garde le présent (le temps d'un run), Parquet gardera l'historique (étape 8).

Prochaine étape

Étape 3 — Mesure de la machine : vérifier Ollama et les modèles Qwen3, régler ses variables (modèles gardés en mémoire, requêtes parallèles), puis mesurer la latence de chaque modèle en séquentiel et en parallèle. Ces mesures remplaceront les durées supposées du document d'architecture et serviront de base au coût (E4).

Étape 3 — Mesure de la machine

16 octobre 2026 · Exigences concernées : E4 (coût d'un run), E5 (sobriété), A5 (modèles de tailles différentes), et l'objectif O4 (identifier le facteur limitant).

Objectif

Remplacer les durées *supposées* du document d'architecture par des durées *mesurées* sur la machine du projet, avant d'écrire le moindre agent. On sait ainsi combien de temps durera un run, combien de mémoire graphique prend chaque modèle, et ce que coûte le passage d'un palier à l'autre.

Ce qui a été fait

- **Téléchargement des trois modèles** Qwen3 : `qwen3:1.7b` (1,4 Go), `qwen3:4b` (2,5 Go), `qwen3:8b` (5,2 Go). Le premier réseau plafonnait à 140 Ko/s ; le changement de réseau a permis de finir à environ 10 Mo/s.
- **Réglage d'Ollama** par six variables d'environnement utilisateur (tableau ci-dessous), prises en compte au redémarrage d'Ollama.
- **Script de benchmark** `llm/benchmark.py`, relançable sur n'importe quelle machine (`python -m llm.benchmark`), y compris celle de la collaboratrice.
- **Résultats enregistrés** dans `docs/mesures/` : un résumé lisible (Markdown) et toutes les mesures brutes, appel par appel (JSON).
- **Bibliothèques ajoutées** : `ollama` (client officiel, qui servira aussi à l'étape 6) et `httpx` (requêtes HTTP simples).

Les réglages d'Ollama

Variable	Valeur	Raison
`OLLAMA_MAX_LOADED_MODELS`	3	Petit, moyen et modèle d'embeddings doivent rester chargés ensemble. Le document d'architecture proposait 2, mais le modèle d'embeddings compte aussi comme un modèle.
`OLLAMA_NUM_PARALLEL`	4	Jusqu'à 4 requêtes traitées en même temps par un modèle.
`OLLAMA_KEEP_ALIVE`	30m	Un modèle reste en mémoire 30 minutes après son dernier appel, pour éviter des rechargements.
`OLLAMA_FLASH_ATTENTION`	1	Calcul de l'attention plus rapide et plus économe ; nécessaire pour compresser le cache.
`OLLAMA_KV_CACHE_TYPE`	q8_0	Le cache de contexte est stocké sur 8 bits au lieu de 16 : deux fois moins de VRAM.
`OLLAMA_CONTEXT_LENGTH`	2048	Un prompt d'agent fait environ 650 tokens : 2 048 suffit et réserve moins de VRAM par requête.

Comment on a mesuré

Chaque appel imite une **décision d'agent** : un prompt d'environ 650 tokens (profil, jour, zone, météo, trois messages reçus, quatre passages « retrouvés »), une réponse JSON imposée (`action`, `sens`, `message`, `justification`), la réflexion de Qwen3 désactivée. Les prompts varient d'un appel à l'autre, mais de façon

déterministe, pour que le benchmark soit reproductible. Le nom de marque vient de la configuration, jamais du code.

Pour chaque modèle : un chargement à froid, 12 appels l'un après l'autre, puis 12 appels par paquets de 2 et de 4 en parallèle. Pendant chaque série, `nvidia-smi` relève quatre fois par seconde la puissance, la mémoire et la température du GPU. On mesure enfin la **bascule de palier** : charger le 8b alors que le 1.7b et le 4b sont en mémoire, puis revenir au 1.7b.

Résultats

Mesure	qwen3:1.7b	qwen3:4b	qwen3:8b
VRAM occupée (modèle + cache pour 4 requêtes)	1,7 Go	3,1 Go	5,4 Go
Part du modèle sur le GPU	100 %	100 %	100 %
Latence médiane d'une décision, en séquentiel	0,76 s	1,49 s	2,14 s
Latence supposée dans le document d'architecture	0,8 s	1,5 s	3 s
Meilleur débit (décisions par minute)	108 (2 en parallèle)	78 (4 en parallèle)	58 (4 en parallèle)
Vitesse de génération en séquentiel	167 tokens/s	84 tokens/s	55 tokens/s
Énergie GPU par décision (séquentiel → meilleur parallèle)	56 → 40 J	109 → 56 J	167 → 79 J

Pendant le calcul, le GPU consomme environ 76 W et monte jusqu'à 80 °C (8b, 4 requêtes en parallèle).

Ce que les mesures nous apprennent

Constat	Conséquence
Les latences confirment les hypothèses, et le 8b est même plus rapide que prévu (2,1 s au lieu de 3 s).	Le dimensionnement tient. Pour les 2 155 appels estimés d'un run : environ 41 min en séquentiel, environ 25 min avec le meilleur parallélisme de chaque palier.
Le parallélisme double le débit du 4b et du 8b et divise par deux l'énergie par décision.	Argument direct pour la sobriété (E5) : regrouper les appels coûte moins cher.
La bascule de palier est coûteuse : charger le 8b décharge à la fois le 1.7b et le 4b (6,5 s), et revenir coûte environ 3 s par modèle. Un aller-retour ≈ 13 s.	Si le palier grand est appelé un jour sur deux, cela ajoute environ 10 minutes par run. L'ordonnancement par palier (étape 5) doit limiter le nombre de bascules.
Les réponses sont plus longues que prévu : environ 110 tokens au lieu de 70.	À maîtriser à l'étape 6 (justification plus courte).
Seules 2 réponses sur 117 sont invalides (1,7 %), et toutes pour la même raison : elles atteignent le plafond de 160 tokens et le JSON est coupé. Aucune réponse n'est hors schéma.	Le JSON imposé fonctionne même sur le 1.7b. À l'étape 6 : plafond relevé ou réponses raccourcies, et le mécanisme « une relance puis repli » (A4) couvrira le reste.
Le 1.7b à 4 requêtes simultanées est instable : la première vague d'appels prend 4 à 12 s avant de revenir à la normale (constaté deux fois).	Pour le palier petit, on visera 2 requêtes en parallèle ; 4 pour les paliers moyen et grand.
Les modèles ont une préférence : sur des situations variées, le 8b a répondu « tendance » 24 fois sur 38.	Point d'attention pour la question Q2 du jury : un sens partagé peut venir du modèle lui-même et non de la diffusion. Le run témoin de l'étape 14 devra le mesurer.

> **Premier chiffrage de la sobriété (E5), à confirmer à l'étape 16.** Avec la répartition prévue (270 appels au 8b, 715 au 4b, 1 170 au 1.7b), un run consomme environ 110 kJ côté GPU, soit 0,03 kWh, et environ 25 min de calcul. Les mêmes 2 155 appels tous sur le 8b demanderaient environ 170 kJ et 37 min. Ces chiffres ne comptent que le GPU pendant les appels, sans les bascules ni le reste de la machine.

État du dépôt après l'étape

```
llm/benchmark.py                            script de mesure, relançable
docs/mesures/benchmark_2026-10-16_1143.md   résumé des mesures
docs/mesures/benchmark_2026-10-16_1143.json  mesures brutes, appel par appel
tests/test_benchmark.py                     2 tests (prompt déterministe, taille)
```

Tests : 18 tests réussis, aucune remarque de ruff.

À retenir pour l'oral

- Le dimensionnement repose sur des **mesures**, pas sur des hypothèses : chaque chiffre renvoie à un fichier de `docs/mesures/`, appel par appel.
- Le facteur limitant est la **mémoire graphique** : les trois modèles ne tiennent pas ensemble, et changer de palier coûte environ 13 s. C'est ce qui justifie l'ordonnancement par palier.
- La mesure de l'énergie est en place dès maintenant : le coût de chaque run (E4) pourra être comparé à son apport (E1).

Prochaine étape

Étape 4 — Contrat d'événements : l'enveloppe commune à tous les événements (identifiant, version de schéma, `run_id`, deux horloges, `caused_by`), les schémas Pydantic de chaque type d'événement, et l'isolement des événements non conformes dans `sim.dlq`.